作业 _Week6

20244227004 蔡博凯

2024 年 10 月 25 日

第一题 现有一个由 20 个贷款申请数据组成训练集 D（表 1），类别为是否同意发放。

（1）请用 ID3 算法（即以信息增益选择划分属性）生成一颗用于发放贷款的决策树。

（2）请对生成的决策树根据表 2 里的验证集进行后剪枝。

表1 训练集

ID	有无工作	有无房子	信贷情况	类别
1	否	否	一般	否
2	否	否	好	否
3	是	否	好	是
4	是	是	一般	是
5	否	否	一般	否
6	否	否	一般	否
7	否	否	好	否
8	是	是	好	是
9	否	是	非常好	是
10	否	是	好	是
11	否	是	非常好	是
12	否	是	好	是
13	是	否	好	是
14	是	否	非常好	是
15	否	否	一般	否
16	否	否	好	否
17	是	是	一般	是
18	否	否	好	否
19	否	是	一般	是
20	否	否	非常好	否

表2 验证集

ID	有无工作	有无房子	信贷情况	类别
1	是	否	好	否
2	是	是	一般	是
3	否	否	好	否
4	是	是	好	是
5	是	否	非常好	否
6	否	是	好	是
7	否	否	非常好	否
8	是	是	好	否

解答

(1) 生成决策树

给定训练集 D，特征集 A，A1 表示有无工作，A2 表示有无房子，A3 表示信贷情况

1. 首先整理训练集 D 如下表所示

属性	值	样本数	” 是” 样本数	” 否” 样本数
有无工作	是	6	6	0
	否	14	5	9
合计		20	11	9
有无房子	是	8	8	0
	否	12	3	9
合计		20	11	9
信贷情况	一般	7	3	4
	好	9	5	4
	非常好	4	3	1
合计		20	11	9

表 1: 训练集 D

2. 计算各特征信息增益

以计算 A_1 的信息增益为例

$$\mathrm{H}(D) = -\left(\frac{11}{20}\log_2\left(\frac{11}{20}\right) + \frac{9}{20}\log_2\left(\frac{9}{20}\right)\right) \approx 0.993$$

$$\begin{aligned}\mathrm{H}(D|A_1) = &-\left(\frac{6}{6}\log_2\left(\frac{6}{6}\right) + \frac{0}{6}\log_2\left(\frac{0}{6}\right)\right) \times \frac{6}{20} \\ &-\left(\frac{5}{14}\log_2\left(\frac{5}{14}\right) + \frac{9}{14}\log_2\left(\frac{9}{14}\right)\right) \times \frac{14}{20} \approx 0.658\end{aligned}$$

$$g(D, A_1) = H(D) - H(D|A_1) \approx 0.993 - 0.658 = 0.335$$

同理可得，

$$g(D, A_2) = H(D) - H(D|A_2) \approx 0.993 - 0.487 = 0.506$$

$$g(D, A_3) = H(D) - H(D|A_3) \approx 0.993 - 0.953 = 0.040$$

由于

$$g(D, A_2) > g(D, A_1) > g(D, A_3)$$

3. 划分数据集 D

故选择 A_2 作为根结点的特征，它将训练数据集 D 划分为两个子集 D_1(A_2 取值为 “是”) 和 D_2(A_2 取值为 “否”). 由于 D_1 只包含同一类的样本点，所以他成为一个叶节点，节点的类标记为” 是”. 对 D_2 需从 A_1/A_3 中选择新的特征进行划分.

3. 整理训练集 D_2 如下表所示

属性	值	样本数	” 是” 样本数	” 否” 样本数
有无工作	是	3	3	0
	否	9	0	9
合计		12	3	9
信贷情况	一般	4	0	4
	好	6	2	4
	非常好	2	1	1
合计		12	3	9

表 2: 训练集 D_2

4. 计算各特征信息增益

$$g(D_2, A_1) = H(D_2) - H(D_2|A_1) \approx 0.811 - 0 = 0.811$$

$$\mathrm{g}(D_2, A_3) = H(D_2) - H(D_2|A_3) \approx 0.811 - 0.626 = 0.185$$

由于

$$\mathrm{g}(D_2, A_1) > \mathrm{g}(D_2, A_3)$$

5. 划分数据集 D_2

故选择 A_1 作为结点的特征，它将训练数据集 D_2 划分为两个子集 D_3(A_1 取值为“是”) 和 D_4(A_1 取值为“否”). 由于 D_3 只包含同一类的样本点，所以他成为一个叶节点，节点的类标记为” 是”. 由于 D_4 只包含同一类的样本点，所以他成为一个叶节点，节点的类标记为” 否”.

这样生成一个如下图所示的决策树. 该决策树只用了两个特征（有两个内部结点）.

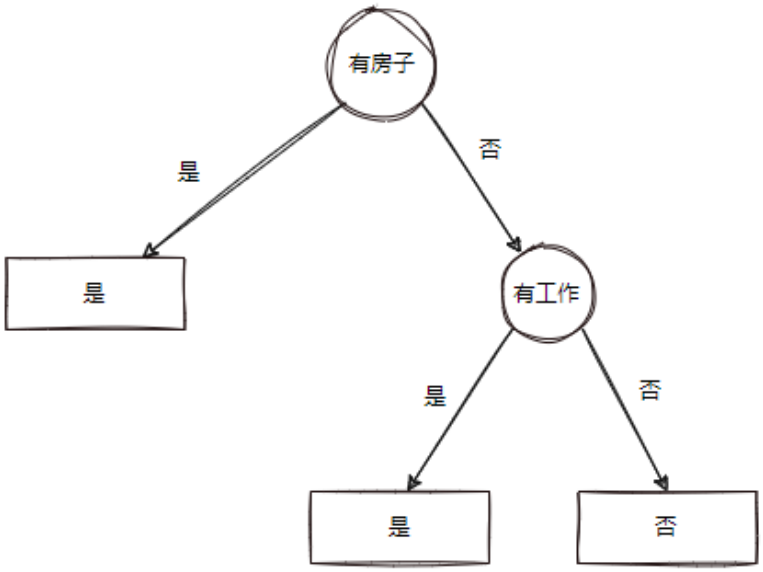


图 1: 决策树的生成

(2) 后剪枝

1. 考虑替换 tree1

由于数据集 D_2 中为” 否” 的样本数多于为” 是” 的样本数，故替换的叶结点标记为” 否”.

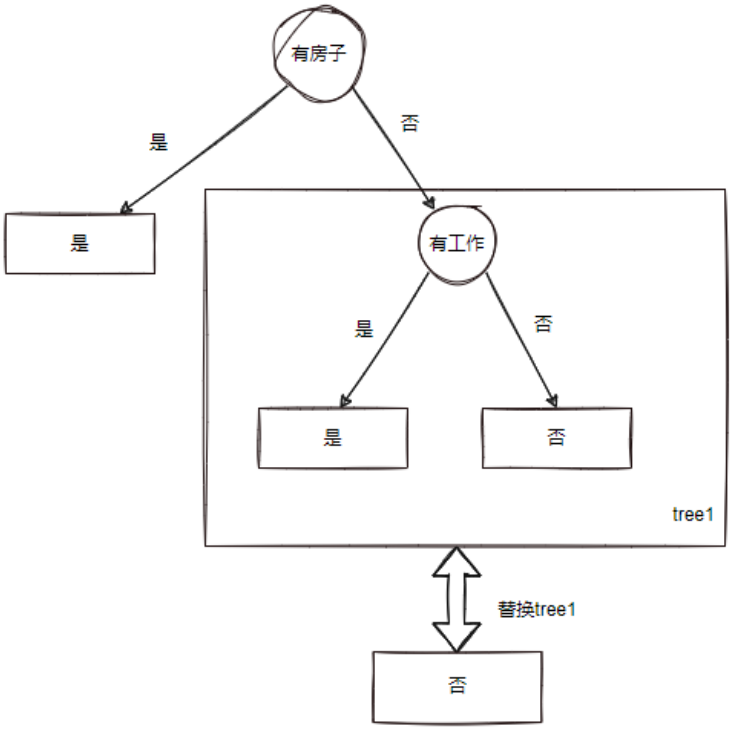


图 2: 替换子树

2. 比较替换前后预测误差, 考虑 ID 为 1，3，5，7 的样本点

数据点	原树判断	替换后判断	验证集类别
1	是	否	否
3	否	否	否
5	是	否	否
7	否	否	否

表 3: 原树与替换后判断结果

	原准确率	替换后准确率
准确率	50%	100%

表 4: 准确率对比

可以剪枝，由于验证集中既有为” 是” 的类别，又有为” 否” 的类别，因此不再考虑替换根节点所在子树. 剪枝后的结果如下图所示.

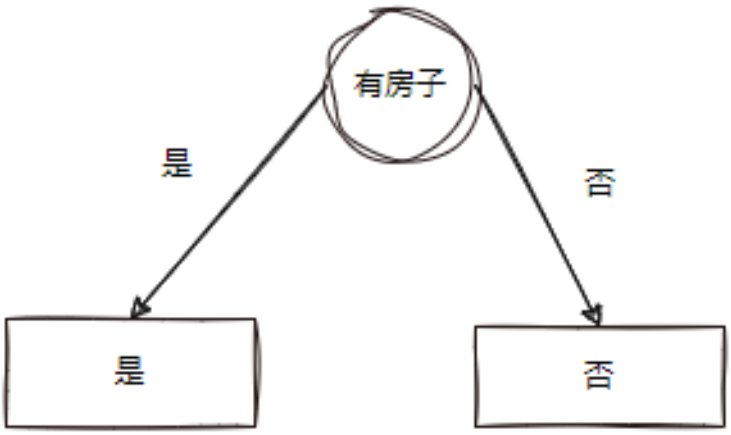


图 3: 后剪枝

第二题 试用极大似然法估算表 3 中前三个属性的类条件概率 $P(x_i \mid c)$。

表3

编号	色泽	根蒂	敲声	纹理	脐部	触感	密度	含糖率	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	0.697	0.460	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	0.774	0.376	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	0.634	0.264	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	0.608	0.318	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	0.556	0.215	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	0.403	0.237	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	0.481	0.149	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	0.437	0.211	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	0.666	0.091	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	0.243	0.267	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	0.245	0.057	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	0.343	0.099	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	0.639	0.161	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	0.657	0.198	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	0.360	0.370	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	0.593	0.042	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	0.719	0.103	否

编号	色泽	根蒂	敲声	纹理	脐部	触感	密度	含糖率	好瓜
测 1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	0.697	0.460	?

解答

1. 问题设定

对于类别 Y，我们需要估计属性 A 的各个取值 a_1, a_2, a_3 的条件概率

$$p_1 = P(A = a_1|Y = y), \quad p_2 = P(A = a_2|Y = y), \quad p_3 = P(A = a_3|Y = y)$$

并且满足：

$$p_1 + p_2 + p_3 = 1$$

2. 构造似然函数并取对数

假设属性 A 的取值频次为：

$$N_1 = N(A = a_1|Y = y), \quad N_2 = N(A = a_2|Y = y), \quad N_3 = N(A = a_3|Y = y)$$

总样本数 $N = N_1 + N_2 + N_3$。于是，似然函数为：

$$L(p_1, p_2, p_3) = p_1^{N_1} \cdot p_2^{N_2} \cdot p_3^{N_3}$$

对似然函数取对数：

$$LL(p_1, p_2, p_3) = N_1 \ln(p_1) + N_2 \ln(p_2) + N_3 \ln(p_3)$$

利用 $p_3 = 1 - p_1 - p_2$ 代入，得到：

$$LL(p_1, p_2) = N_1 \ln(p_1) + N_2 \ln(p_2) + N_3 \ln(1 - p_1 - p_2)$$

3. 求偏导

- 对 p_1 求偏导：

$$\frac{\partial LL}{\partial p_1} = \frac{N_1}{p_1} - \frac{N_3}{1 - p_1 - p_2}$$

令其等于 0：

$$\frac{N_1}{p_1} = \frac{N_3}{1 - p_1 - p_2} \tag{1}$$

- 对 p_2 求偏导：

$$\frac{\partial LL}{\partial p_2} = \frac{N_2}{p_2} - \frac{N_3}{1 - p_1 - p_2}$$

令其等于 0：

$$\frac{N_2}{p_2} = \frac{N_3}{1 - p_1 - p_2} \tag{2}$$

从方程 (1) 和 (2) 可以解得：

$$p_1 = \frac{N_1}{N_1 + N_2 + N_3}, \quad p_2 = \frac{N_2}{N_1 + N_2 + N_3}$$

根据约束条件 $p_1 + p_2 + p_3 = 1$，可以得到：

$$p_3 = 1 - p_1 - p_2$$

4. 整理数据集 D 并代入上式如表 5 所示

特征	类别	样本数	” 是” 样本数	” 否” 样本数	P(Y = ” 是”)	P(Y = ” 否”)
色泽	乌黑	6	4	2	4 / 8	2 / 9
	浅白	5	1	4	1 / 8	4 / 9
	青绿	6	3	3	3 / 8	3 / 9
合计		17	8	9		
根蒂	蜷缩	8	5	3	5 / 8	3 / 9
	稍蜷	7	3	4	3 / 8	4 / 9
	硬挺	2	0	2	0 / 8	2 / 9
合计		17	8	9		
敲声	浊响	10	6	4	6 / 8	4 / 9
	沉闷	5	2	3	2 / 8	3 / 9
	清脆	2	0	2	0 / 8	2 / 9
合计		17	8	9		

表 5: 不同属性下的好瓜和坏瓜统计及类条件概率

5. 拉普拉斯平滑

在极大似然估计过程中，如果某类样本点的数量为零，通常会遇到零概率问题, 比如上表中根蒂为硬挺在条件为” 是” 下的概率。为了解决这一问题，采用拉普拉斯平滑技术。具体步骤如下：对每个可能的属性值的计数都加上 1。在分母中，增加的值是 k，即所有可能属性值的总数。经过平滑后的估计如下表。

特征	类别	P(Y = ” 是”)	P(Y = ” 否”)
色泽	青绿	5 / 11	3 / 12
	乌黑	2 / 11	5 / 12
	浅白	4 / 11	4 / 12
根蒂	蜷缩	6 / 11	4 / 12
	稍蜷	4 / 11	5 / 12
	硬挺	1 / 11	3 / 12
敲声	浊响	7 / 11	5 / 12
	沉闷	3 / 11	4 / 12
	清脆	1 / 11	3 / 12

表 6: 类条件概率表

参考文献

[1] https://github.com/hanmq/MachineLearning_Zhouzhihua_ProblemSets

[2] 李航. 统计学习方法.